Derivaciones y Análisis sintáctico

- Derivación izquierda [derecha]: el próximo no terminal a expandir es el que se encuentre más a la izquierda [derecha]
- Un parser top-down parte del axioma y despliega el AAS en concordancia con una derivación izquierda
- Un parser bottom-up va reduciendo desde las hojas hacia el axioma, en concordancia con el orden inverso de una derivación derecha

Gramáticas Ambiguas

- Una gramática es ambigua si hay dos posibles derivaciones del mismo tipo (izquierda o derecha) para la misma cadena
- También podemos reconocerlas por poder armar dos AAS para la misma cadena
- Sea la gramática

Regla Nro	Regla
1	Exp → Exp + Exp
2	Exp → Exp * Exp
3	Expr → Nro
4	Nro → 0 | 1 | 2 | 3 | 4 | 5

Ejemplo Ambiguas

Cadena: 2 + 3 * 5

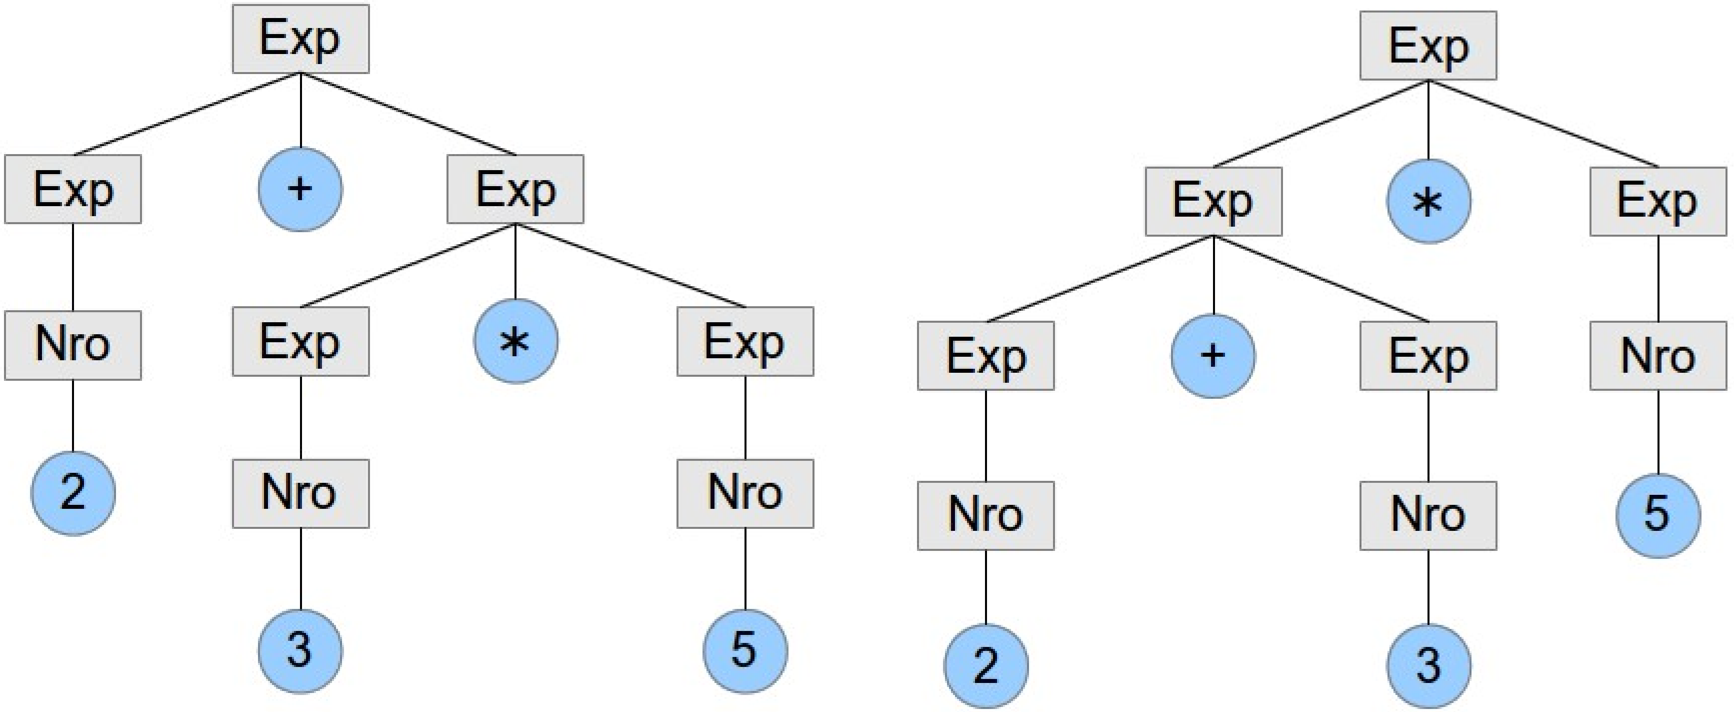

Determinación de Ambigüedad

- Determinar si una GIC es ambigua es un problema indecidible, es decir, no existe algoritmo que tomando cualquier GIC conteste por si o no.
- Sin embargo si es posible determinarlo para algunas clases de gramáticas
- Para demostrar que es ambigua basta con encontrar una cadena que admita dos árboles de derivación diferentes.
- Demostrar que es no ambigua se complica más, hay que demostrar que en ningún caso voy a poder armar dos árboles de derivación diferentes
- Es sabido que las gramáticas LL(k) y LR(k) que veremos a continuación no son ambiguas

LL

- Un análisis sintáctico LL (**L**eft to right, **L**eftmost derivation) significa que se hace recorriendo los tokens de izquierda a derecha y derivando a izquierda
  - Es lo que se usa en el ASDR (top-down)
  - Implica desplegar el AAS desde la raíz, primero en profundidad, en pre orden
- Una gramática LL es una GIC que **admite un análisis sintáctico** LL
- Se dice que es LL(**k**) si puedo decidir que producción usar conociendo anticipadamente los próximos **k** símbolos de preanálisis (tokens)
- Un parser LL(k) es conocido también como un parser predictivo (elimina la necesidad de backtracking gracias a los k símbolos de preanálisis)

LR

- El caso LR (**L**eft to right, reversed **R**ightmost derivation) se usa en parsers bottom-up
- Invierte una derivación a derecha, es decir, reduce primero la última derivación y va armando el AAS hacía su axioma.
- Lo habitual es implementarlos usando una herramienta tipo bison en lugar de programarlos a mano
- Al igual que con los LL se usan símbolos de preanálisis, teniendo gramáticas LR(k)
- Reconocen un grupo más amplio de lenguajes que las gramáticas LL
- Permite una mejor (más temprana) detección de errores que el análisis sintáctico LL

LL(1)

- Un caso de interés es el LL(1) ya que permite un algoritmo muy eficiente que decide que producción usar con un único **símbolo de preanálisis**
- Obviamente no todas las GIC son LL(1)
- Ejemplos
  - $S \rightarrow aR \mid b$ es LL(1)
  - $S \rightarrow aR \mid a$ NO es LL(1)
  - $S \rightarrow abQ \mid acM$ NO es LL(1) , es LL(2)

Recursividad a Izquierda

- Supongamos la producción: expr → expr + term | term
- Como vimos los no terminales llaman a un PAS
- Si expr, basado en el ProximoToken decide llamar a la primera producción, llamaría a expr que … termina generando un loop infinito, porque **solo Match avanza el token leído**.
- Eliminación
  - Tengo $A \rightarrow A\alpha \mid \beta$
  - En definitiva genera una β seguida de α^* , entonces puedo reemplazar por
  - $A \rightarrow \beta R$
$R \rightarrow \alpha R \mid \varepsilon$
  - donde R es un nuevo terminal que agrega una producción recursiva a derecha

Factorizar a Izquierda

- Hay casos en que no puedo usar LL(1) porque varias producciones comienzan igual. En forma general si tengo
  - $A \rightarrow \alpha\beta_1 \mid \alpha\beta_2 \mid \ldots \mid \alpha\beta_n$
- Convierto con un Nuevo no terminal auxiliar
  - $A \rightarrow \alpha B$
  - $B \rightarrow \beta_1 \mid \beta_2 \mid \ldots \mid \beta_n$
- Ejemplo
  - <sentencia if> → if (<condición>) <sentencia> else <sentencia> |
    if (<condición>) <sentencia>

    if (<condición>) <sentencia> == α
    else <sentencia> == β_1
    ε == β_2

    <sentencia if> → if (<condición>) <sentencia> <opción else>
    <opción else> → else <sentencia> | ε

Elegir la producción siguiente

- En una parser predictivo debemos poder seleccionar la siguiente producción basados en el siguiente token. Para ello nos valdremos de los conjuntos **primero** y **siguiente**.
- El conjunto primero de un símbolo terminal o no terminal de la gramática es el conjunto de los primeros tokens que pueden ser derivados del símbolo analizado
- Si el símbolo analizado es un terminal, entonces su conjunto primero es ese mismo terminal: Primero(a) = {a}
- Si A solo tiene la producción $A \rightarrow \alpha$ entonces Primero(A) = Primero(α) que es el conjunto de tokens (terminales) que pueden dar inicio a α siguiendo todas las derivaciones posibles de α

Conjunto Primero

- Si $A \rightarrow \alpha \mid \beta$ entonces
  $\text{Primero}(A) = \text{Primero}(\alpha) \cup \text{Primero}(\beta)$. Para poder decidir que producción utilizar con un único símbolo de preanálisis, debe cumplirse que
  $\text{Primero}(\alpha) \cap \text{Primero}(\beta) = \varnothing$
- Más genéricamente, para que una gramática sea LL(1) si tengo $A \rightarrow \alpha \mid \beta \mid \gamma$
  - Quiero con el terminal siguiente saber que producción usar, para eso busco los conjuntos primeros de cada uno de los lados derechos.
  - Entonces Primero(α), Primero(β) y Primero(γ) deben ser conjuntos disjuntos
- Si A produce o puede derivar en ε entonces ε pertenece a Primero(A)

Armado del conjunto Primero

- Vamos a calcular Primero(α) suponiendo que $\alpha = X_1X_2...X_n$
- Si X_1 es terminal, entonces Primero(α) = {X1}
- Si X_1 es NO terminal, entonces calculamos Primero(X_1) buscando todas las producciones con X_1 a la izquierda y hacemos la unión de los conjuntos primeros de las partes derechas de esas producciones y agregamos el resultado a Primero(α)
  - Si Primero(X_1) incluye ε NO lo Agregamos a Primero(α)
- Si X_1 puede generar ε entonces todo pasa a depender de X_2 a quien aplican las mismas reglas que a X_1 y en modo similar si X_2 genera ε iré por X_3.
- Si ($X_1X_2...X_n$) puede generar ε, entonces ε es parte del conjunto Primero($X_1X_2...X_n$)
  - Este es el único caso en que agregamos ε a Primero(α)

Conjunto Siguiente

- Si $A \rightarrow \alpha$ y α es o genera ε (X_i genera ε $\forall_i$) entonces no tengo un token dentro de su conjunto primero que me indique que esta es la producción a seleccionar. Este caso hace necesario fijarnos en el conjunto Siguiente(A)
- El conjunto siguiente de un NO terminal A es el conjunto de tokens que pueden aparecer inmediatamente después A
- Decimos que **a** pertenece al conjunto siguiente de **A** si: $S \Rightarrow^* \alpha \mathbf{A} \mathbf{a} \beta$
  - Notar que en algún momento puedo haber un no terminal entre A y a, que luego derivó en ε

Armado del conjunto Siguiente

- Buscamos todas las producciones donde en su parte derecha figure A:
  - Si tenemos una producción del tipo $T \rightarrow \alpha A \beta$ entonces incorporamos Primero(β) a Siguiente(A) pero sin incluir ε en el caso que fuese parte de Primero(β)
  - Si tenemos una producción del tipo $T \rightarrow \alpha A$, es decir A es el último símbolo de la producción, entonces agrego Siguiente(T) a Siguiente(A)
  - Notar que si en nuestro primer caso ε forma parte de Primero(β), cuando β deriva en ε nos queda en la forma del segundo caso, debiendo entonces agregar a Siguiente(A) tanto Primero(β) como Siguiente(T).
- Comentario: podría ocurrir que no haya nada a derecha de A. El modo de resolverlo es considerando que FDT forma parte de Siguiente(A)
  - Esto nos lleva a que FDT siempre forma parte del conjunto siguiente del Axioma.

Función Predice

- Combina las dos anteriores para obtener finalmente el conjunto de terminales que nos permitan elegir la producción a utilizar
- Predice($A \rightarrow X_1X_2...X_n$) :
  - Primero($X_1X_2...X_n$) si $\varepsilon \notin$ Primero($X_1X_2...X_n$)
  - (Primero($X_1X_2...X_n$) - {ε}) ∪ Siguiente(A) en caso contrario
- Por tanto para que la gramática sea LL(1)
  Si $A \rightarrow \alpha_1 \mid \alpha_2 \mid \ldots \mid \alpha_n$ debe cumplirse:
  - Los conjuntos Primero(α_i) son disjuntos
  - Esto implica que ε solo puede pertenecer a uno de esos conjuntos
  - Si $\varepsilon \in$ Primero(α_k) entonces
    Siguiente(A) ∩ Primero(α_i) = ∅ ∀ i≠k

Parser predictivo no recursivo

- Vamos a usar una pila (como en los AFP) y una tabla que permita seleccionar la producción a utilizar (basada en la función predice)
- La Tabla tiene No terminales como filas y los terminales más FDT como columnas. En cada intersección pondremos la producción a aplicar (o el número la misma).
- Supongamos la gramática de $a^n b^n$ / $n \geq 0$
- $S \rightarrow aSb \mid \varepsilon$

Armado de la tabla

- Regla **1**: S → aSb
  Primero(aSb) = {a} por tanto
  Predice(aSb) = {a}
- Regla **2**: S → ε
  Primero(ε) = {ε} por tanto debo calcular
  Siguiente(S) = {b, fdt} entonces
  Predice(ε) = {b, fdt}
- Tabla

	a	b	fdt	otros
S	1	2	2	-

Algoritmo

- Comenzamos poniendo en la pila $ y el Axioma.
- Repetimos
  - Sea **t** el siguiente símbolo (token) en la cadena a analizar y **X** el símbolo en el tope de la pila
  - Si **X** es $ y **t** es fdt entonces paramos y reportamos éxito
  - Si **X** es un terminal
    - Si **X** = **t** entonces avanzamos al siguiente token a analizar y hacemos pop en la pila para eliminar **X** del tope.
    - Sino: error sintáctico (similar al que daría match(**t**))

Algoritmo (continuación)

- Repetimos (continuación)
  - Si **X** es un NO terminal consultamos la Tabla(X,t).
    - Si indica una regla: $X \rightarrow Y_1 Y_2 \cdots Y_n$ hacemos pop para eliminar X y push en orden inverso de los Y_i de modo que Y_n quede al fondo e Y1 al tope de la pila.
      - Notar: no avanzamos en la cadena a analizar.
    - Si está indefinido, o sea, no hay regla que aplicar: error sintáctico.

Pseudocódigo

```
push($)
push(axioma)
token <- leer_token()
repetir indefinidamente
    tope <- copia_tope_pila()
    si tope == $ Y token == fdt
        retornar éxito
    si tope es terminal
        si tope == token
            pop()
            token <- leer_token()
        sino
            error sintáctico
    sino //tope es NO terminal
        si tabla(tope, token) definida como A -> B1B2…Bn
            pop()
            push(Bn) … push(B2) push(B1)
        sino
            error sintáctico
```

Ejemplo

	a	b	fdt	otros
S	1: S → aSb	2: S → ε	2: S → ε	-

Pila	Cadena remanente	Regla - Acción
S$	aabb fdt	1 - pop + push
aSb$	aabb fdt	pop + avanzar
Sb$	abb fdt	1 - pop + push
aSbb$	abb fdt	pop + avanzar
Sbb$	bb fdt	2 - pop (push ε)
bb$	bb fdt	pop + avanzar
b$	b fdt	pop + avanzar
$	fdt	Reconoce

Licencia